

Statistique Descriptive

Pr. Iaousse

EST Casablanca

2025-2026

À l'issue de ce cours, l'étudiant sera capable de :

- **Conceptualiser** les étapes d'une étude statistique complète.
- **Maîtriser** les outils de synthèse numérique et graphique pour l'analyse univariée et bivariée.
- **Interpréter** rigoureusement les indicateurs de position, dispersion, forme et concentration.
- **Appliquer** les méthodes de corrélation et de régression pour modéliser des relations.
- **Justifier** le choix d'un indicateur en fonction du type de variable et de l'objectif d'analyse.

1. Introduction
2. Tableaux statistiques et Visualisation des Données
3. Indicateurs de Position
4. Indicateurs de Dispersion
5. Analyse de la Forme
6. Analyse de la Concentration
7. Statistique Bivariée : Étude des Relations

Introduction

Définition et Champs d'Application

Qu'est-ce que la Statistique ?

Définition

*La statistique est l'ensemble des méthodes scientifiques qui permettent de **collecter**, **organiser**, **résumer**, **présenter**, **analyser** et **interpréter** des données pour prendre des décisions éclairées.*

- **Statistique Descriptive** : Décrire et résumer les données observées (notre focus).
- **Statistique Inférentielle** : Généraliser les résultats d'un échantillon à une population.

- ❶ **Collecte des données** : Enquête, recensement, observation.
- ❷ **Organisation des données** : Tri, classement, construction de tableaux.
- ❸ **Synthèse et Analyse** : Calcul d'indicateurs et représentation graphique.
- ❹ **Interprétation et Décision** : Conclusion et aide à la prise de décision.

Exemple : Gestion des Stocks

Une entreprise analyse les ventes des 12 derniers mois (collecte). Elle calcule la moyenne et l'écart-type des ventes (synthèse) pour déterminer le stock de sécurité optimal (décision).

Vocabulaire Fondamental et Notations

Population, Individu, Échantillon

Définition

Population (Ω) : Ensemble d'unités partageant une ou plusieurs caractéristiques communes et faisant l'objet de l'étude.

Définition

Individu (ou Unité Statistique) : Élément de la population.

Définition

Échantillon : Sous-ensemble représentatif de la population, de taille n .

Notation

- Taille de la population : N (grande lettre).
- Taille de l'échantillon : n (petite lettre).

Définition

Variable (ou Caractère) : Propriété observée ou mesurée sur chaque individu. Notée X .

Définition

Modalité : Valeur possible que peut prendre la variable X .

Exemple : Étude de Marché

- Population : Clients d'un supermarché.
- Variable X : Satisfaction (Modalités : Très satisfait, Satisfait, Insatisfait).
- Variable Y : Montant des achats (Valeurs : 50DH, 120DH, etc.).

Paramètre vs Statistique

Définition

Paramètre : Mesure décrivant une caractéristique de la **population** (ex : moyenne vraie μ).

Définition

Statistique : Mesure calculée sur un **échantillon** (ex : moyenne observée $\bar{x}$).

Propriété

La statistique est utilisée pour **estimer** le paramètre.

Typologie des Variables

Définition


*Une variable est **qualitative** si ses modalités ne sont pas mesurables numériquement mais décrivent une qualité ou une catégorie.*

- **Nominale** : Pas d'ordre naturel entre les modalités (ex : Sexe, Couleur, Filière).
- **Ordinale** : Les modalités peuvent être ordonnées (ex : Mention, Niveau de satisfaction, Classe sociale).

Définition

*Une variable est **quantitative** si ses modalités sont des nombres résultant d'une mesure ou d'un dénombrement.*

- **Discrète** : Ne peut prendre qu'un nombre fini ou dénombrable de valeurs (souvent des entiers) (ex : Nombre d'enfants, Nombre de modules validés).
- **Continue** : Peut prendre n'importe quelle valeur dans un intervalle donné (ex : Taille, Poids, Température, Durée).



Exercice

Le code postal est-il une variable quantitative ? Justifiez.

Exercices

- ❶ **Étude sur les PME** Une étude porte sur 1000 Petites et Moyennes Entreprises (PME) d'une région.
 - Définir la population, l'individu et l'échantillon.
 - Proposer 5 variables pertinentes pour cette étude et les classer.
- ❷ **Classification des Variables** Classer les variables suivantes : (a) Chiffre d'affaires annuel, (b) Secteur d'activité, (c) Note de crédit (A, B, C, D), (d) Nombre de brevets déposés, (e) Température d'un four industriel, (f) Code postal.
- ❸ **Paramètre vs Statistique** Expliquer la différence entre le taux de chômage réel (paramètre) et le taux de chômage estimé par une enquête (statistique). Pourquoi la statistique varie-t-elle d'un échantillon à l'autre ?

- ④ **Enquête de Satisfaction** Un hôtel interroge 200 clients sur leur séjour. Les variables étudiées sont : (a) Note globale (1 à 5 étoiles), (b) Nationalité, (c) Durée du séjour (nuits), (d) Montant dépensé au restaurant.
- Identifier la population, l'individu et l'échantillon.
 - Classer chaque variable (type et sous-type).
- ⑤ **Analyse d'un Processus de Production** Une usine fabrique des bouteilles. On mesure : (a) le volume (mL), (b) la présence de défaut (oui/non), (c) le numéro de la machine, (d) la gravité du défaut (mineur, majeur, critique).
- Quelle est la population ? L'individu ?
 - Pour chaque variable, indiquer le type et proposer un graphique adapté.
- ⑥ **Question Conceptuelle** Le numéro de sécurité sociale est-il une variable quantitative ? Justifier.

- 7 **Étude Médicale** Un hôpital étudie 500 patients atteints de diabète. Variables : âge, sexe, type de diabète (1 ou 2), taux de glycémie (g/L), nombre de consultations par an, niveau de risque cardiovasculaire (faible/moyen/élevé).
- Identifier la population et l'individu statistique.
 - Classer chaque variable et proposer une mesure de tendance centrale adaptée.
- 8 **Sondage Électoral** Un institut interroge 1500 personnes sur leurs intentions de vote.
- L'intention de vote est-elle une variable qualitative nominale ou ordinale ? Justifier.
 - Si l'on demande aussi le degré de certitude (très sûr, assez sûr, hésitant), quelle est la nature de cette variable ?
- 9 **Données Manquantes** Dans une enquête, 15% des répondants n'ont pas indiqué leur revenu.
- Proposer trois stratégies pour traiter ces valeurs manquantes.
 - Quelle stratégie privilégier si les non-réponses concernent surtout les hauts revenus ?

Tableaux statistiques et Visualisation des Données

Séries Statistiques et Distribution

Série Brute et Série Ordonnée

Définition

Série Brute : Liste des observations dans l'ordre de collecte : $x_1, x_2, \dots, x_n$.

Définition

Série Ordonnée : Liste des observations triées par ordre croissant : $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$.

Utilité

La série ordonnée est indispensable pour le calcul de la **médiane** et des **quartiles**.

Tableau de Distribution (Variable Discrète)

Définition

Le tableau de distribution regroupe les valeurs distinctes x_i avec leurs effectifs n_i et fréquences f_i .

x_i (Valeur)	n_i (Effectif)	f_i (Fréquence)	N_i (Effectif Cumulé)	F_i (Fréquence Cumulée)
x_1	n_1	f_1	$N_1 = n_1$	$F_1 = f_1$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_p	n_p	f_p	$N_p = n$	$F_p = 1$
Total	n	1		

Définition

Effectif Cumulé Croissant (N_i) : Nombre d'individus ayant une valeur inférieure ou égale à x_i .

$$N_i = \sum_{j=1}^i n_j$$

Fréquence Cumulée Croissante (F_i) : Proportion d'individus ayant une valeur inférieure ou égale à x_i .

$$F_i = \sum_{j=1}^i f_j$$

Propriété

Les cumuls ne sont pertinents que pour les variables **quantitatives** et **qualitatives ordinales**.

Regroupement en Classes (Variable Continue)

- Pour une variable continue, chaque observation est souvent unique.
- Le regroupement en **classes** (intervalles) est nécessaire pour synthétiser l'information.

Définition

Classe : Intervalle $[a_i, a_{i+1}[$. **Amplitude** : $h_i = a_{i+1} - a_i$. **Centre de Classe** : $c_i = \frac{a_i + a_{i+1}}{2}$.

Détermination du Nombre de Classes (k)

- Le choix de k est un compromis entre perte d'information (trop peu de classes) et lisibilité (trop de classes).
- **Règle de Sturges** (la plus utilisée) :

$$k \approx 1 + 3.322 \log_{10}(n)$$

- **Règle de la Racine Carrée** :

$$k \approx \sqrt{n}$$

Procédure

- ➊ Calculer l'étendue $E = x_{\max} - x_{\min}$.
- ➋ Déterminer k (par Sturges ou $\sqrt{n}$).
- ➌ Calculer l'amplitude $h \approx E/k$ (arrondir à une valeur simple).
- ➍ Définir les classes contiguës $[a_0, a_1[, [a_1, a_2[, \dots$



Tableau de Distribution (Classes)

Classe	Centre c_i	Amplitude h_i	n_i	f_i	F_i
$[a_1, a_2[$	c_1	h_1	n_1	f_1	F_1
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$[a_k, a_{k+1}]$	c_k	h_k	n_k	f_k	$F_k = 1$
Total			n	1	

Représentations Graphiques

Graphiques pour Variables Qualitatives

- **Diagramme en secteurs (camembert)** : L'angle est proportionnel à la fréquence ($\alpha_i = 360^\circ \times f_i$).
- **Diagramme en barres** : Les barres sont **disjointes** (séparées).



Règle


Utiliser le camembert pour peu de modalités (< 6). Au-delà, préférer les barres.

Exemple : Diagramme en Secteurs

Données : Répartition de 50 étudiants par filière : GI (20), GE (15), TM (10), GC (5).

Solution :

Filière	n_i	f_i	Angle α_i
GI	20	0.40	144°
GE	15	0.30	108°
TM	10	0.20	72°
GC	5	0.10	36°
Total	50	1.00	360°




Calcul : $\alpha_{GI} = 360 \times 0.40 = 144^\circ$, etc.

Définition

Diagramme en Bâtons : Chaque valeur x_i est représentée par un segment vertical dont la hauteur est proportionnelle à l'effectif n_i .


- Les bâtons sont **séparés** (pas de continuité entre les valeurs).
- Adapté aux variables discrètes (nombre d'enfants, nombre de pannes, etc.).



Exemple : Diagramme en Bâtons

Données : Nombre de pannes par mois sur 50 mois d'observation.

Pannes (x_i)	n_i	f_i
0	5	0.10
1	12	0.24
2	18	0.36
3	10	0.20
4	5	0.10
Total	50	1.00




Mode : $Mo = 2$ pannes (effectif max = 18).

Courbe Cumulative (Variable Discrète)

Définition

Pour une variable **discrète**, la courbe des fréquences cumulées est une **fonction en escalier**.

- Les sauts se produisent aux valeurs x_i observées.
- Entre deux valeurs consécutives, $F(x)$ reste constante.




Lecture : $F(2) = 0.70$ signifie que 70% des mois ont ≤ 2 pannes.

Exemple : Courbe Cumulative (Discrète)

Suite de l'exemple des pannes.

x_i	n_i	N_i	F_i
0	5	5	0.10
1	12	17	0.34
2	18	35	0.70
3	10	45	0.90
4	5	50	1.00



Médiane : $F(1) = 0.34 < 0.5$ et $F(2) = 0.70 \geq 0.5 \Rightarrow Me = 2$ pannes.

Définition

Histogramme : Succession de rectangles **contigus**. C'est l'**aire** qui représente l'effectif (ou la fréquence).

Méthode de construction :

- 1 Identifier les bornes des classes $[e_i, e_{i+1}[$.
- 2 Calculer l'amplitude $h_i = e_{i+1} - e_i$.
- 3 Calculer la **densité** (hauteur) $d_i = \frac{n_i}{h_i}$ (ou f_i/h_i).

Attention

Si les amplitudes sont égales, la hauteur est proportionnelle à l'effectif. Si elles sont inégales, la hauteur est obligatoirement la densité.

Exemple : Histogramme (Données)

Contexte : Analyse de 100 délais de livraison (en jours).


Classe	h_i	n_i	f_i	$d_i = f_i/h_i$
$[0, 2[$	2	30	0.30	0.150
$[2, 3[$	1	25	0.25	0.250
$[3, 5[$	2	20	0.20	0.100
$[5, 10]$	5	25	0.25	0.050
Total		100	1.00	

Calcul des densités :

- $d_1 = 0.30/2 = 0.15$, $d_2 = 0.25/1 = 0.25$, $d_3 = 0.20/2 = 0.10$, $d_4 = 0.25/5 = 0.05$

Vérification : $\sum h_i \times d_i = 2(0.15) + 1(0.25) + 2(0.10) + 5(0.05) = 1 \checkmark$

Exemple : Histogramme (Tracé)



- La classe $[2, 3[$ a la plus grande **densité** (0.25) mais pas le plus grand effectif.
- Classe modale par densité : $[2, 3[$.

L'Ogive des Fréquences Cumulées (Variable Continue)

Définition


L'**ogive** est la courbe des fréquences cumulées pour une variable **continue**. On relie les points (e_{i+1}, F_i) par des segments de droite.

- C'est une courbe **continue** (contrairement à l'escalier pour les discrètes).
- Elle permet de lire graphiquement la médiane et les quartiles.

Exemple : Ogive (Données et Tracé)

Suite de l'exemple des délais de livraison.

Borne sup.	N_i	F_i
0	0	0
2	30	0.30
3	55	0.55
5	75	0.75
10	100	1.00



Médiane graphique : Intersection avec $F = 0.5 \Rightarrow Me \approx 2.8$ jours.

Calcul : $Me = 2 + 1 \times \frac{0.5 - 0.30}{0.25} = 2 + 0.8 = 2.8$ jours.

Synthèse : Quel Graphique Choisir ?

Type de variable	Graphique	Courbe cumulative
Qualitative nominale	Barres, Camembert	–
Qualitative ordinale	Barres	Escalier (optionnel)
Quantitative discrète	Bâtons	Escalier
Quantitative continue	Histogramme	Ogive

Règles importantes

- **Bâtons** : segments séparés (valeurs isolées).
- **Histogramme** : rectangles contigus (intervalles).
- **Escalier** : sauts aux valeurs discrètes.
- **Ogive** : courbe continue par interpolation linéaire.

Exercices

- ❶ **Construction de Tableau (Discrète)** Soit la série brute des notes (sur 20) de 20 étudiants : 12, 15, 8, 10, 12, 15, 18, 10, 10, 12, 14, 15, 10, 12, 14, 15, 10, 12, 14, 15.
 - Construire le tableau de distribution complet $(x_i, n_i, f_i, N_i, F_i)$.
 - Représenter la distribution par un diagramme en bâtons.
 - Quelle est la note la plus fréquente ?
- ❷ **Regroupement en Classes** Pour une série de 150 salaires (en kDH) allant de 15 à 85.
 - Déterminer le nombre de classes k par Sturges et par $\sqrt{n}$.
 - Proposer des classes d'amplitude égale et calculer leur centre.
- ❸ **Interprétation Graphique** Expliquer pourquoi l'histogramme est plus adapté qu'un diagramme en bâtons pour la variable "Durée de vie d'un produit (en heures)".

- 4 **Analyse des Temps d'Attente** Un centre d'appels a enregistré les temps d'attente (en minutes) de 80 clients :

Classe	$[0, 2[$	$[2, 4[$	$[4, 6[$	$[6, 10[$	$[10, 20]$
n_i	20	25	18	12	5

- Compléter le tableau (f_i , N_i , F_i , centre c_i , amplitude h_i , densité d_i).
 - Tracer l'histogramme en utilisant les densités (amplitudes inégales).
 - Tracer l'ogive et estimer graphiquement la médiane.
- 5 **Qualitative Nominale** Dans une enquête sur 200 personnes, on obtient : Transport en commun (70), Voiture (85), Vélo (25), Marche (20).
- Construire le tableau des fréquences.
 - Représenter par un diagramme circulaire (calculer les angles).

Exercices (3/3)

- 6 **Ogive et Lecture Graphique** À partir de l'ogive d'une série, on lit $F(15) = 0.20$, $F(20) = 0.45$, $F(25) = 0.70$, $F(30) = 1$.
- Dans quelle classe se trouve la médiane? Justifier.
 - Estimer Q_1 et Q_3 graphiquement.
- 7 **Erreur Courante** Un étudiant trace un histogramme pour des classes d'amplitudes inégales en utilisant directement les effectifs n_i comme hauteurs. Expliquer l'erreur commise et donner un contre-exemple numérique.
- 8 **Choix du Graphique** Pour chaque variable, proposer le graphique le plus adapté et justifier :
- (a) Répartition des ventes par région (5 régions).
 - (b) Distribution des âges des employés (données continues).
 - (c) Nombre d'accidents par jour (0, 1, 2, 3, 4+).
 - (d) Évolution du chiffre d'affaires (12 mois).
- 9 **Série Qualitative Ordinale** Niveau de satisfaction : Très insatisfait (5), Insatisfait (12), Neutre (18), Satisfait (40), Très satisfait (25). Construire le tableau complet avec cumuls et représenter graphiquement.

Indicateurs de Position

La Moyenne Arithmétique

Définition de la Moyenne Arithmétique

Définition

La **moyenne arithmétique** ($\bar{x}$) est la somme des valeurs divisée par le nombre d'observations n .

- **Série brute :**

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- **Série groupée (discrète) :**

$$\bar{x} = \frac{1}{n} \sum_{i=1}^p n_i x_i = \sum_{i=1}^p f_i x_i$$

- **Série groupée (classes) :** On utilise le centre de classe c_i comme approximation.

$$\bar{x} \approx \frac{1}{n} \sum_{i=1}^k n_i c_i$$

Propriétés de la Moyenne

Propriété (Centre de Gravité)

La somme des écarts à la moyenne est nulle :

$$\sum_{i=1}^n (x_i - \bar{x}) = 0$$

Propriété (Linéarité)

Si $y_i = ax_i + b$, alors $\bar{y} = a\bar{x} + b$.

Limitation

La moyenne est très **sensible aux valeurs extrêmes** (outliers).

Définition (Moyennes Spéciales)

Moyenne Pondérée : Utilisée lorsque les valeurs ont des importances différentes (w_i : poids ou coefficients).

$$\bar{x}_w = \frac{\sum w_i x_i}{\sum w_i}$$

Moyenne Géométrique : Utilisée pour moyenner des taux de croissance ou des facteurs multiplicatifs ($x_i > 0$).

$$G = \left(\prod_{i=1}^n x_i \right)^{1/n}$$

Moyenne Harmonique : Utilisée pour moyenner des rapports (vitesses, débits) lorsque les numérateurs sont égaux.

$$H = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}}$$

Exemple : Moyenne Pondérée

Contexte : Calcul de la moyenne générale d'un étudiant avec coefficients.

Matière	Note (x_i)	Coefficient (w_i)	$w_i \times x_i$
Mathématiques	14	4	56
Informatique	16	3	48
Physique	12	2	24
Anglais	15	1	15
Total		10	143

$$\bar{x}_w = \frac{143}{10} = 14.3$$

Interprétation : La moyenne pondérée (14.3) est différente de la moyenne simple $(14 + 16 + 12 + 15)/4 = 14.25$.

Exemple : Moyenne Géométrique

Contexte : Taux de croissance annuel d'une entreprise sur 4 ans.

- Année 1 : +20% (facteur 1.20)
- Année 2 : -10% (facteur 0.90)
- Année 3 : +15% (facteur 1.15)
- Année 4 : +5% (facteur 1.05)

Calcul :

$$G = (1.20 \times 0.90 \times 1.15 \times 1.05)^{1/4} = (1.3041)^{0.25} = 1.0687$$

Taux moyen : 6.87% par an.

Vérification : Un capital de 1000 DH après 4 ans :

$$1000 \times 1.20 \times 0.90 \times 1.15 \times 1.05 = 1304.10 \text{ DH}$$

$$1000 \times (1.0687)^4 = 1304.10 \text{ DH} \quad \checkmark$$

Théorème (Inégalité des Moyennes)

Pour toute série de valeurs strictement positives, on a :

$$H \leq G \leq \bar{x}$$

L'égalité n'est vérifiée que si toutes les valeurs sont identiques.

Exemple

Un aller-retour de 100 km : 60 km/h à l'aller, 90 km/h au retour.

- Moyenne arithmétique : $(60 + 90)/2 = 75$ km/h (Incorrecte).
- Moyenne harmonique : $H = \frac{2}{\frac{1}{60} + \frac{1}{90}} = 72$ km/h (Correcte).

La Médiane et le Mode

Définition

La **médiane** est la valeur qui divise la série ordonnée en deux parties égales (50% des observations sont inférieures ou égales à Me).

- **Série brute :**

- n impair : $Me = x_{(\frac{n+1}{2})}$.

- n pair : $Me = \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2}$ (par convention).

- **Série groupée (cumuls) :** Me est la plus petite valeur x_i telle que $F_i \geq 0.5$.

Calcul de la Médiane par Interpolation (Classes)

- **Étape 1** : Identifier la **classe médiane** (celle où F_i dépasse 0.5).
- **Étape 2** : Appliquer la formule d'interpolation linéaire :

$$Me = L + h \cdot \frac{0.5 - F_{\text{avant}}}{f_{\text{classe}}}$$

où :

- L : Borne inférieure de la classe médiane.
- h : Amplitude de la classe médiane.
- F_{avant} : Fréquence cumulée avant la classe médiane.
- f_{classe} : Fréquence de la classe médiane.

Le Mode (Mo)

Définition

Le **mode** est la modalité ou la valeur qui a le plus grand effectif (n_i).

- **Variable qualitative** : Toujours pertinent.
- **Variable discrète** : Valeur avec le n_i maximal.
- **Variable continue** : On parle de **classe modale** (classe avec le n_i maximal, ou le d_i maximal si amplitudes inégales).

Propriété

Une distribution peut être **unimodale** (un seul mode), **bimodale** (deux modes) ou **multimodale**.

Relation entre Moyenne, Médiane et Mode

Propriété (Relation Empirique de Pearson)

Pour une distribution **unimodale modérément asymétrique**, on a la relation approximative :

$$\bar{x} - Mo \approx 3(\bar{x} - Me)$$

Ou de manière équivalente :

$$Mo \approx 3 \cdot Me - 2 \cdot \bar{x}$$

- **Distribution symétrique** : $\bar{x} = Me = Mo$
- **Asymétrie positive (à droite)** : $Mo < Me < \bar{x}$
- **Asymétrie négative (à gauche)** : $\bar{x} < Me < Mo$

Attention

Cette relation est **empirique** et n'est valable que pour des distributions unimodales et modérément asymétriques.

Calcul du Mode par Interpolation (Classes)

- **Étape 1** : Identifier la **classe modale** $[L, L + h[$.
- **Étape 2** : Appliquer la formule d'interpolation (méthode de Czuber) :

$$Mo = L + h \cdot \frac{\Delta_1}{\Delta_1 + \Delta_2}$$

où :

- Δ_1 : Différence entre l'effectif de la classe modale et celui de la classe précédente.
- Δ_2 : Différence entre l'effectif de la classe modale et celui de la classe suivante.

Les Quantiles

Définition des Quantiles

Définition

Les **quantiles** sont des valeurs qui partagent la série ordonnée en q parties égales.

- **Quartiles** ($q = 4$) : Q_1, Q_2, Q_3 . Q_2 est la médiane.
- **Déciles** ($q = 10$) : $D_1, D_2, \dots, D_9$.
- **Centiles** ($q = 100$) : $C_1, C_2, \dots, C_{99}$.

Propriété

Le k -ième quantile est la valeur Q_k telle que k/q des observations lui sont inférieures ou égales.

- **Série brute** : On cherche la position $P = n \cdot (k/4)$.
 - Si P est un entier, Q_k est la moyenne entre $x_{(P)}$ et $x_{(P+1)}$.
 - Si P n'est pas un entier, Q_k est la valeur $x_{(\lceil P \rceil)}$.
- **Série groupée (classes)** : On utilise la formule d'interpolation, en remplaçant 0.5 par $k/4$:

$$Q_k = L + h \cdot \frac{k/4 - F_{\text{avant}}}{f_{\text{classe}}}$$

Exemple : Calcul des Indicateurs de Position

Contexte : Une banque analyse les montants (en kDH) des crédits accordés à 50 clients.

Classe	c_i	n_i	f_i	N_i	F_i
[0, 10[	5	8	0.16	8	0.16
[10, 20[	15	15	0.30	23	0.46
[20, 30[	25	12	0.24	35	0.70
[30, 50[	40	10	0.20	45	0.90
[50, 80]	65	5	0.10	50	1.00
Total		50	1.00		

Exemple : Solutions

1. Moyenne :

$$\bar{x} = \sum f_i c_i = 0.16 \times 5 + 0.30 \times 15 + 0.24 \times 25 + 0.20 \times 40 + 0.10 \times 65 = 24.8 \text{ kDH}$$

2. Médiane : Classe médiane = $[20, 30[$ car $F_{\text{avant}} = 0.46 < 0.5 \leq 0.70 = F_i$.

$$Me = 20 + 10 \times \frac{0.5 - 0.46}{0.24} = 20 + 10 \times 0.167 = 21.67 \text{ kDH}$$

3. Mode : Classe modale = $[10, 20[$ (effectif max = 15).

$$\Delta_1 = 15 - 8 = 7, \quad \Delta_2 = 15 - 12 = 3$$

$$Mo = 10 + 10 \times \frac{7}{7 + 3} = 10 + 7 = 17 \text{ kDH}$$

Interprétation : $Mo < Me < \bar{x} \Rightarrow$ asymétrie à droite (quelques gros crédits tirent la moyenne vers le haut).

Exercices

- ① **Comparaison Moyenne/Médiane** Soit la série des revenus annuels (en kDH) : 20, 25, 30, 35, 40, 50, 200.
 - Calculer $\bar{x}$ et Me .
 - Interpréter l'écart entre les deux. Quel indicateur est le plus pertinent ?
- ② **Moyenne Géométrique** Un investissement a connu les taux de croissance annuels suivants : +10%, -5%, +20%.
 - Quel type de moyenne utiliser pour le taux moyen ? Pourquoi ?
 - Calculer ce taux et vérifier avec le facteur global.
- ③ **Interpolation de la Médiane** Un tableau de classes montre que la classe $[10, 20[$ a $F_{\text{avant}} = 0.4$ et $f_{\text{classe}} = 0.3$.
 - Vérifier que c'est bien la classe médiane.
 - Calculer Me par interpolation.

- 4 **Durées de Réparation** Un atelier de réparation automobile a enregistré les durées (en heures) de 60 interventions :

Classe	$[0, 1[$	$[1, 2[$	$[2, 3[$	$[3, 5[$	$[5, 10]$
n_i	10	20	15	10	5

- Construire le tableau complet (c_i, f_i, N_i, F_i) .
 - Calculer la moyenne, la médiane et le mode par interpolation.
 - Quelle est la position relative de ces trois indicateurs ? Interpréter.
- 5 **Moyenne Harmonique** Un véhicule parcourt 120 km à 60 km/h, puis 120 km à 40 km/h.
- Calculer la vitesse moyenne (attention : ce n'est pas $(60 + 40)/2$).
 - Vérifier en calculant le temps total et la distance totale.

- ❖ **Calcul des Quartiles (Classes)** À partir du tableau de l'exercice 4 :
- Déterminer Q_1 et Q_3 par interpolation.
 - Calculer l'écart interquartile IQR .
- ❖ **Moyenne Pondérée** Un étudiant a obtenu : 12/20 (coef. 3), 15/20 (coef. 2), 8/20 (coef. 1), 14/20 (coef. 4).
- Calculer la moyenne pondérée.
 - Quelle note minimale au dernier examen (coef. 4) aurait-il dû obtenir pour avoir 13/20 de moyenne ?
- ❖ **Série Brute** Données : 5, 7, 8, 8, 9, 10, 10, 10, 12, 15, 42.
- Calculer $\bar{x}$, Me , Mo .
 - La valeur 42 est-elle une valeur aberrante ? Quel indicateur est le plus robuste ?
- ❖ **Inégalité des Moyennes** Pour la série 2, 8 : vérifier que $H \leq G \leq \bar{x}$ et calculer les trois moyennes.

Indicateurs de Dispersion

Mesures Basées sur les Écarts

L'Étendue et l'Écart Interquartile

Définition

Étendue (E) : Différence entre la valeur maximale et la valeur minimale.

$$E = x_{\max} - x_{\min}$$

Définition

Écart Interquartile (IQR) : Mesure la dispersion des 50% centraux de la distribution.

$$IQR = Q_3 - Q_1$$

Propriété

L'étendue est très sensible aux valeurs extrêmes. L'IQR est **robuste**.

La Variance et l'Écart-Type

Définition

La **Variance** (σ^2 ou s^2) est la moyenne des carrés des écarts à la moyenne.

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Définition

L'**Écart-Type** (s) est la racine carrée de la variance. Il est dans la même unité que la variable X .

$$s = \sqrt{s^2}$$

Théorème (Formule de König-Huygens)

La variance peut être calculée plus facilement par :

$$s^2 = \left(\frac{1}{n} \sum_{i=1}^n x_i^2 \right) - \bar{x}^2$$

(Moyenne des carrés moins carré de la moyenne).

- **Série groupée (discrète) :**

$$s^2 = \frac{1}{n} \sum_{i=1}^p n_i x_i^2 - \bar{x}^2$$

- **Série groupée (classes) :** On utilise c_i à la place de x_i .

Mesures de Dispersion Relative

Le Coefficient de Variation (CV)

Définition

Le **Coefficient de Variation** est le rapport de l'écart-type à la moyenne.

$$CV = \frac{s}{\bar{x}} \quad (\text{souvent exprimé en \%})$$

Propriété

Le CV est une mesure **sans unité** (adimensionnelle). Il permet de comparer la dispersion de deux séries de moyennes très différentes.

Interprétation

Si $CV_A = 10\%$ et $CV_B = 30\%$, la série B est trois fois plus dispersée (ou hétérogène) que la série A, relativement à sa propre moyenne.

Variable Centrée Réduite

Définition

La **variable centrée réduite** est définie par :

$$z_i = \frac{x_i - \bar{x}}{s}$$

Propriété

La variable Z a pour moyenne $\bar{z} = 0$ et pour écart-type $s_Z = 1$.

Utilité

Permet de comparer des observations provenant de distributions différentes (ex : comparer une note de maths à une note de français).

La Boîte à Moustaches (Boxplot)

Définition

Le **boxplot** est un graphique qui résume la distribution à partir de Q_1 , Me , Q_3 et des **bornes de Tukey**.

- **Borne inférieure** : $L_{\text{inf}} = Q_1 - 1.5 \times IQR$
- **Borne supérieure** : $L_{\text{sup}} = Q_3 + 1.5 \times IQR$
- Les **moustaches** s'étendent jusqu'aux valeurs extrêmes **dans** ces bornes.
- Les valeurs **au-delà** des bornes sont des **valeurs aberrantes** (outliers), représentées par des points.



Exemple : Construction d'un Boxplot

Données : Crédits bancaires (50 clients). D'après les calculs précédents :

- $\bar{x} = 25.8$ kDH, $Me = 21.67$ kDH
- $Q_1 = 12.33$ kDH (interpolation dans $[10, 20[$)
- $Q_3 = 37.50$ kDH (interpolation dans $[30, 50[$)
- $IQR = Q_3 - Q_1 = 37.50 - 12.33 = 25.17$ kDH

Calcul des bornes de Tukey :

$$L_{\inf} = Q_1 - 1.5 \times IQR = 12.33 - 1.5 \times 25.17 = -25.43 \text{ kDH}$$

$$L_{\sup} = Q_3 + 1.5 \times IQR = 37.50 + 1.5 \times 25.17 = 75.26 \text{ kDH}$$

Interprétation :

- $L_{\inf} < 0$: pas d'outliers inférieurs (crédits ≥ 0).
- $L_{\sup} = 75.26$: les crédits > 75.26 kDH sont des outliers (classe $[50, 80]$ contient des outliers potentiels).
- $Me < \bar{x}$ et Me proche de Q_1 : asymétrie à droite confirmée.

Exemple : Calcul des Indicateurs de Dispersion

Contexte : Reprenons le tableau des crédits bancaires (50 clients).

Classe	c_i	n_i	f_i	$f_i c_i$	$f_i c_i^2$
[0, 10[	5	8	0.16	0.80	4.00
[10, 20[	15	15	0.30	4.50	67.50
[20, 30[	25	12	0.24	6.00	150.00
[30, 50[	40	10	0.20	8.00	320.00
[50, 80]	65	5	0.10	6.50	422.50
Total		50	1.00	25.80	964.00

$$\bar{x} = 25.8 \text{ kDH}, \quad s^2 = 964 - (25.8)^2 = 298.36, \quad s = 17.27 \text{ kDH}$$

$$CV = \frac{17.27}{25.8} = 66.9\% \quad (\text{série très dispersée})$$

Exercices

- ① **Calcul de Variance (König-Huygens)** Soit la série des notes : 10, 12, 14, 16, 18.
 - Calculer $\bar{x}$, s^2 et s avec la formule de König-Huygens.
 - Vérifier avec la formule directe $s^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$.
- ② **Robustesse** Ajouter la valeur 50 à la série précédente.
 - Calculer la nouvelle étendue, $\bar{x}$, s et IQR .
 - Quel indicateur est le moins affecté ? Pourquoi ?
- ③ **Homogénéité (CV)** Comparer deux portefeuilles d'actions :
 - Portefeuille A : $\bar{x}_A = 5\%$, $s_A = 1\%$.
 - Portefeuille B : $\bar{x}_B = 20\%$, $s_B = 5\%$.

Calculer CV_A et CV_B . Quel portefeuille a le risque relatif le plus faible ?

- ④ **Contrôle Qualité** Une usine produit des vis dont le diamètre nominal est 10 mm. On mesure 100 vis :

Classe (mm)	[9.7, 9.8[	[9.8, 9.9[	[9.9, 10.1[	[10.1, 10.2[	[10.2, 10.3]
n_i	5	15	60	15	5

- Calculer $\bar{x}$, s^2 , s et CV .
 - Le cahier des charges impose $CV < 3\%$. La production est-elle conforme ?
 - Calculer Q_1 , Me , Q_3 et tracer un boxplot.
- ⑤ **Propriété de la Variance** Si $y_i = 2x_i + 5$, exprimer $\bar{y}$ et s_Y en fonction de $\bar{x}$ et s_X .
Application : si $\bar{x} = 10$ et $s_X = 3$, calculer $\bar{y}$ et s_Y .

- 6 **Variable Centrée Réduite** Un étudiant a 14/20 en maths ($\bar{x} = 12$, $s = 2$) et 16/20 en anglais ($\bar{x} = 14$, $s = 1$).
- Calculer les notes centrées réduites z_{maths} et z_{anglais} .
 - Dans quelle matière l'étudiant est-il relativement le meilleur ?
- 7 **Boxplot et Asymétrie** Un boxplot montre : $x_{\min} = 5$, $Q_1 = 10$, $Me = 12$, $Q_3 = 20$, $x_{\max} = 35$.
- Calculer IQR et les bornes pour détecter les valeurs aberrantes.
 - La valeur 35 est-elle aberrante ? Et la valeur 5 ?
 - Commenter l'asymétrie de la distribution.
- 8 **Variance d'une Série Groupée** Données : $x = 1$ (effectif 4), $x = 2$ (effectif 6), $x = 3$ (effectif 5), $x = 4$ (effectif 3), $x = 5$ (effectif 2). Calculer $\bar{x}$, s^2 , s et interpréter.
- 9 **Démonstration** Démontrer que $\sum(x_i - \bar{x}) = 0$ (somme des écarts à la moyenne est nulle).

Analyse de la Forme

Moments d'une distribution

Définition

Le **moment d'ordre** k (par rapport à l'origine) est défini par :

$$m_k = \frac{1}{n} \sum_{i=1}^n x_i^k$$

- $m_1 = \bar{x}$: la moyenne (moment d'ordre 1).
- m_2 : utilisé dans le calcul de la variance.

Définition

Le **moment centré d'ordre k** (par rapport à la moyenne) est défini par :

$$\mu_k = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k$$

- $\mu_1 = 0$ (toujours).
- $\mu_2 = s^2$: la variance.
- μ_3 : utilisé pour l'asymétrie.
- μ_4 : utilisé pour l'aplatissement.

Asymétrie (Skewness)


Définition de l'Asymétrie

Définition


*L'**asymétrie** mesure le degré de symétrie de la distribution par rapport à son centre.*

- **Distribution symétrique** : $\bar{x} \approx Me \approx Mo$.
- **Asymétrie à droite (positive)** : La queue est plus longue à droite. $\bar{x} > Me$.
- **Asymétrie à gauche (négative)** : La queue est plus longue à gauche. $\bar{x} < Me$.


Illustration de l'Asymétrie



Asymétrie à gauche ($\gamma_1 < 0$)



Symétrique ($\gamma_1 \approx 0$)



Asymétrie à droite ($\gamma_1 > 0$)

Coefficient d'Asymétrie de Fisher (γ_1)

Définition

Le **coefficient d'asymétrie de Fisher** est basé sur le moment centré d'ordre 3 (μ_3).

$$\gamma_1 = \frac{\mu_3}{s^3} = \frac{\frac{1}{n} \sum (x_i - \bar{x})^3}{s^3}$$

- $\gamma_1 > 0$: Asymétrie positive (à droite).
- $\gamma_1 < 0$: Asymétrie négative (à gauche).
- $\gamma_1 \approx 0$: Distribution symétrique.

Coefficient d'Asymétrie de Pearson

Définition

Le **coefficient d'asymétrie de Pearson** est une mesure simple basée sur la relation entre la moyenne et le mode (ou la médiane).

$$A_P = \frac{\bar{x} - Mo}{s} \quad \text{ou} \quad A_P \approx \frac{3(\bar{x} - Me)}{s}$$

Propriété

Pour une distribution unimodale modérément asymétrique, on a la relation empirique :
 $\bar{x} - Mo \approx 3(\bar{x} - Me)$.

Exemple 1 : Distribution Symétrique

Données : Notes de 9 étudiants : 6, 8, 10, 11, 12, 13, 14, 16, 18.

Calculs :

- $\bar{x} = \frac{6+8+10+11+12+13+14+16+18}{9} = \frac{108}{9} = 12$
- $Me = x_{(5)} = 12$ (valeur centrale)
- $Mo = 12$ (distribution uniforme, mais centrage sur 12)
- $s = 3.74$ (calculé)

Coefficient de Pearson :

$$A_P = \frac{3(\bar{x} - Me)}{s} = \frac{3(12 - 12)}{3.74} = 0$$

Interprétation : $A_P = 0$ et $\bar{x} = Me \Rightarrow$ distribution **symétrique**.

Exemple 2 : Asymétrie Positive (à Droite)

Données : Revenus mensuels (en kDH) de 8 employés : 3, 4, 4, 5, 5, 6, 8, 25.

Calculs :

- $\bar{x} = \frac{3+4+4+5+5+6+8+25}{8} = \frac{60}{8} = 7.5$ kDH
- $Me = \frac{x_{(4)} + x_{(5)}}{2} = \frac{5+5}{2} = 5$ kDH
- $Mo = 4$ et 5 (bimodal, mais classe modale autour de 4-5)
- $s = 6.93$ kDH (calculé)

Coefficient de Pearson :

$$A_P = \frac{3(\bar{x} - Me)}{s} = \frac{3(7.5 - 5)}{6.93} = \frac{7.5}{6.93} = 1.08$$

Interprétation : $A_P > 0$ et $Mo < Me < \bar{x} \Rightarrow$ asymétrie **positive** (la valeur 25 tire la moyenne vers le haut).

Exemple 3 : Asymétrie Négative (à Gauche)

Données : Durée de vie (en années) de 8 appareils : 1, 8, 9, 10, 10, 11, 11, 12.

Calculs :

- $\bar{x} = \frac{1+8+9+10+10+11+11+12}{8} = \frac{72}{8} = 9$ ans
- $Me = \frac{x_{(4)} + x_{(5)}}{2} = \frac{10+10}{2} = 10$ ans
- $Mo = 10$ et 11 (classes modales)
- $s = 3.32$ ans (calculé)

Coefficient de Pearson :

$$A_P = \frac{3(\bar{x} - Me)}{s} = \frac{3(9 - 10)}{3.32} = \frac{-3}{3.32} = -0.90$$

Interprétation : $A_P < 0$ et $\bar{x} < Me < Mo \Rightarrow$ asymétrie **négative** (la valeur 1 tire la moyenne vers le bas).

Aplatissement (Kurtosis)

Définition de l'Aplatissement

Définition

*L'**aplatissement** (kurtosis) mesure la concentration des observations autour de la moyenne et l'épaisseur des queues de la distribution.*

- On utilise la distribution **normale** comme référence.

Coefficient d'Aplatissement de Fisher (γ_2)


Définition

Le **coefficient d'aplatissement de Fisher** (excès de kurtosis) est basé sur le moment centré d'ordre 4 (μ_4).

$$\gamma_2 = \frac{\mu_4}{s^4} - 3$$

- $\gamma_2 \approx 0$: **Mésokurtique** (similaire à la loi normale).
- $\gamma_2 > 0$: **Leptokurtique** (pic plus pointu, queues plus épaisses $\Rightarrow$ plus de valeurs extrêmes).
- $\gamma_2 < 0$: **Platykurtique** (pic plus plat, queues plus fines $\Rightarrow$ moins de valeurs extrêmes).

Illustration de l'Aplatissement



- **Leptokurtique** : Queues lourdes, plus de valeurs extrêmes.
- **Platykurtique** : Queues légères, moins de valeurs extrêmes.

Exercices

- ❶ **Interprétation de l'Asymétrie** Le revenu moyen d'une population est de 30 000DH et la médiane est de 25 000DH.
 - Quel est le sens de l'asymétrie ?
 - Interpréter ce résultat en termes de répartition des richesses.
- ❷ **Analyse du Kurtosis** Un analyste trouve $\gamma_2 = 1.5$ pour les rendements boursiers.
 - La distribution est-elle leptokurtique ou platykurtique ?
 - Que cela signifie-t-il pour la gestion du risque ?
- ❸ **Boxplot et Asymétrie** Dessiner un boxplot qui illustre une asymétrie négative. Justifier votre dessin.

- ④ **Coefficient de Pearson** Une série a : $\bar{x} = 50$, $Me = 45$, $s = 15$.
- Calculer le coefficient d'asymétrie de Pearson $A_P = \frac{3(\bar{x} - Me)}{s}$.
 - Interpréter le résultat.
- ⑤ **Analyse de Salaires** Dans une entreprise, on observe : $\bar{x} = 3500DH$, $Me = 3000DH$, $Mo = 2800DH$, $s = 1200DH$.
- Quelle est la position relative de ces trois indicateurs ?
 - En déduire le sens de l'asymétrie et interpréter.
 - Calculer A_P et commenter son intensité.
- ⑥ **Relation Empirique** Vérifier que $\bar{x} - Mo \approx 3(\bar{x} - Me)$ pour les données de l'exercice 5.

- 7 **Interprétation d'un Histogramme** Un histogramme présente une longue queue à gauche et un pic à droite.
- Quel est le sens de l'asymétrie ?
 - Comment se positionnent $\bar{x}$, Me et Mo ?
 - Donner un exemple concret de variable ayant cette forme.
- 8 **Kurtosis et Valeurs Extrêmes** Deux distributions ont le même $\bar{x}$ et le même s . L'une a $\gamma_2 = 0$, l'autre $\gamma_2 = 3$.
- Laquelle a plus de valeurs extrêmes ?
 - Dessiner schématiquement les deux distributions superposées.
- 9 **Symétrie et Moyenne** Pour une distribution parfaitement symétrique, que peut-on dire de $\bar{x}$, Me et Mo ? Donner un exemple de série symétrique de 7 valeurs.

Analyse de la Concentration

Concept de Concentration

Qu'est-ce que la Concentration ?

Définition

La **concentration** mesure la répartition d'une variable quantitative positive (ex : revenu, richesse, production) entre les individus.

- **Égalité parfaite** : Chaque individu détient la même part.
- **Concentration maximale** : Un seul individu détient la totalité.

Domaines d'Application

- Revenus : Répartition des salaires (inégalités).
- Marketing : Parts de marché (domination).
- Production : Répartition des défauts (principe de Pareto).

Le Principe de Pareto (80/20)

Définition

Le **principe de Pareto** (ou loi des 80/20) est une observation empirique selon laquelle environ 80% des effets proviennent de 20% des causes.

- **Origine** : L'économiste Vilfredo Pareto observa que 80% des terres en Italie appartenaient à 20% de la population.
- **Applications** :
 - 80% du chiffre d'affaires provient de 20% des clients.
 - 80% des bugs sont causés par 20% du code.
 - 80% des réclamations concernent 20% des produits.

Interprétation graphique

Sur la courbe de Lorenz, le point $(0.20, 0.80)$ correspondrait à une situation où 20% des individus détiennent 80% de la variable. Si la courbe passe en dessous de ce point, la concentration est **supérieure** au principe de Pareto.


La Courbe de Lorenz

Définition

La **Courbe de Lorenz** est un graphique qui relie la proportion cumulée d'individus (en abscisse) à la proportion cumulée de la variable (en ordonnée).

- Les individus doivent être triés par ordre croissant de la variable.
- **Ligne d'Égalité** : La diagonale $y = x$ représente l'égalité parfaite.
- **Interprétation** : Plus la courbe s'éloigne de la diagonale (plus elle est creusée), plus la concentration est forte.


Représentation de la Courbe de Lorenz



Exemple 1 : Inégalités Réduites

Contexte : Revenus mensuels (en kDH) de 5 employés : 8, 10, 12, 14, 16.

i	x_i	p_i	P_i	Q_i
1	8	0.20	0.20	0.133
2	10	0.20	0.40	0.300
3	12	0.20	0.60	0.500
4	14	0.20	0.80	0.733
5	16	0.20	1.00	1.000
Total	60	1.00		




Calcul de Q_i : $Q_1 = 8/60 = 0.133$, $Q_2 = 18/60 = 0.300$, etc.

Observation : La courbe est proche de la diagonale $\Rightarrow$ **faibles inégalités.**

Exemple 2 : Inégalités Fortes

Contexte : Revenus mensuels (en kDH) de 5 employés : 2, 3, 5, 10, 80.

i	x_i	p_i	P_i	Q_i
1	2	0.20	0.20	0.020
2	3	0.20	0.40	0.050
3	5	0.20	0.60	0.100
4	10	0.20	0.80	0.200
5	80	0.20	1.00	1.000
Total	100	1.00		



Observation : La courbe est très creusée $\Rightarrow$ **fortes inégalités.**

80% des individus (les 4 premiers) ne détiennent que 20% du total (parfait 80/20 inversé).

La Médiale

Définition

La **médiale** est la valeur qui divise la **somme totale** de la variable en deux parties égales.

- C'est la valeur x^* telle que la somme des valeurs $\leq x^*$ représente 50% de la somme totale.
- **Graphiquement** : Sur la courbe de Lorenz, c'est l'abscisse P^* correspondant à $Q = 0.5$.
- **Formule** : Si $Q_{\text{avant}} < 0.5 \leq Q_i$, alors :

$$P^* = P_{i-1} + (P_i - P_{i-1}) \cdot \frac{0.5 - Q_{\text{avant}}}{Q_i - Q_{\text{avant}}}$$

Relation Médiane / Médiale

- **Médiane** : 50% des **individus** ont une valeur inférieure.
- **Médiale** : 50% de la **somme totale** est détenue par les individus ayant une valeur inférieure.
- Si médiale $\gg$ médiane : forte concentration (peu d'individus détiennent beaucoup).

Exemple : Calcul de la Médiale

Exemple 2 (Inégalités fortes) : Revenus 2, 3, 5, 10, 80 (Total = 100).

On cherche P^* tel que $Q(P^*) = 0.5$.

- À $P_4 = 0.80$, on a $Q_4 = 0.20 < 0.5$.
- À $P_5 = 1.00$, on a $Q_5 = 1.00 \geq 0.5$.

$$P^* = 0.80 + (1.00 - 0.80) \times \frac{0.5 - 0.20}{1.00 - 0.20} = 0.80 + 0.20 \times \frac{0.30}{0.80} = 0.875$$

Interprétation :

- La médiane correspond à $P = 0.5$ (le 3ème individu sur 5).
- La médiale correspond à $P^* = 0.875$ (entre le 4ème et 5ème individu).
- **87.5% des individus détiennent 50% de la richesse totale.**
- L'écart médiale-médiane confirme les **fortes inégalités**.

L'Indice de Gini

Définition

*L'**Indice de Gini** est une mesure synthétique de la concentration, basée sur l'aire entre la courbe de Lorenz et la ligne d'égalité.*

$$G = \frac{\text{Aire entre la diagonale et la courbe de Lorenz}}{\text{Aire totale sous la diagonale}}$$

- $G \in [0, 1]$.
- $G = 0$: Égalité parfaite.
- $G = 1$: Concentration maximale.

- Pour une série groupée, on utilise la formule basée sur les trapèzes :

$$G \approx 1 - \sum_{i=1}^k (P_i - P_{i-1})(Q_i + Q_{i-1})$$

où P_i est la fréquence cumulée des individus et Q_i est la fréquence cumulée de la variable.

Interprétation

- $G < 0.25$: Faibles inégalités
- $0.25 \leq G < 0.40$: Inégalités modérées
- $G \geq 0.40$: Fortes inégalités

Exemple : Calcul de l'Indice de Gini

Reprenons les deux exemples précédents.

Exemple 1 (Inégalités réduites) : Revenus 8, 10, 12, 14, 16.

$$\begin{aligned} G_1 &= 1 - [0.2(0 + 0.133) + 0.2(0.133 + 0.300) + 0.2(0.300 + 0.500) \\ &\quad + 0.2(0.500 + 0.733) + 0.2(0.733 + 1.000)] \\ &= 1 - 0.2 \times (0.133 + 0.433 + 0.800 + 1.233 + 1.733) = 1 - 0.866 = \mathbf{0.134} \end{aligned}$$

Exemple 2 (Inégalités fortes) : Revenus 2, 3, 5, 10, 80.

$$\begin{aligned} G_2 &= 1 - [0.2(0 + 0.02) + 0.2(0.02 + 0.05) + 0.2(0.05 + 0.10) \\ &\quad + 0.2(0.10 + 0.20) + 0.2(0.20 + 1.00)] \\ &= 1 - 0.2 \times (0.02 + 0.07 + 0.15 + 0.30 + 1.20) = 1 - 0.348 = \mathbf{0.652} \end{aligned}$$

Conclusion : $G_1 = 0.134$ (faibles inégalités) vs $G_2 = 0.652$ (fortes inégalités).

Exercices

- ❶ **Interprétation de la Courbe** Si 80% des individus détiennent 50% de la richesse, où se situe le point (P_i, Q_i) sur la courbe de Lorenz ? Comment interprétez-vous cela ?
- ❷ **Calcul de Gini (Simplifié)** Soit une population de 4 individus avec les revenus suivants : 10, 20, 30, 40.
 - Calculer les P_i et Q_i cumulés.
 - Tracer la courbe de Lorenz.
 - Calculer l'indice de Gini.
- ❸ **Comparaison de Concentration** Le Gini des ventes du Produit A est 0.15. Le Gini des ventes du Produit B est 0.45.
 - Quel produit a la concentration la plus forte ?
 - Quelle stratégie marketing pour le Produit B ?

- 4 **Parts de Marché** Cinq entreprises se partagent un marché avec les parts suivantes : 5%, 10%, 15%, 20%, 50%.
- Trier par ordre croissant et calculer les (P_i, Q_i) .
 - Tracer la courbe de Lorenz.
 - Calculer l'indice de Gini et interpréter.
 - Ce marché est-il proche d'une situation de monopole ?
- 5 **Égalité Parfaite** Quatre individus ont chacun un revenu de 25.
- Tracer la courbe de Lorenz.
 - Que vaut l'indice de Gini ? Pourquoi ?
- 6 **Concentration Maximale** Un individu détient 100 et trois autres détiennent 0.
- Tracer la courbe de Lorenz.
 - Vers quelle valeur tend l'indice de Gini ?

- 7 **Principe de Pareto (80/20)** Dans une entreprise, 20% des clients génèrent 80% du chiffre d'affaires.
- Placer ce point sur la courbe de Lorenz.
 - Que peut-on dire de la concentration des ventes ?
 - Est-ce une situation courante en business ?
- 8 **Comparaison Internationale** Pays A : $Gini = 0.25$. Pays B : $Gini = 0.55$.
- Quel pays a les inégalités de revenus les plus fortes ?
 - Quelles mesures pourraient réduire le Gini du Pays B ?
- 9 **Interprétation Graphique** Une courbe de Lorenz est très proche de la diagonale pour les premiers 80% de la population, puis s'en éloigne fortement pour les derniers 20%.
- Que signifie cette forme ?
 - Donner un exemple concret de variable ayant cette caractéristique.

Statistique Bivariée : Étude des Relations

Relation entre deux Variables Qualitatives

Tableau de Contingence (Tableau Croisé)

Définition

Le **tableau de contingence** croise les modalités de deux variables qualitatives X et Y .

$X \setminus Y$	Y_1	$\dots$	Total $n_{i.}$
X_1	n_{11}	$\dots$	$n_{1.}$
$\vdots$	$\vdots$	$\ddots$	$\vdots$
Total $n_{.j}$	$n_{.1}$	$\dots$	n

- n_{ij} : Effectif conjoint.
- $n_{i.}$: Effectif marginal de X_i .
- $n_{.j}$: Effectif marginal de Y_j .

Définition

Fréquence Conditionnelle : Proportion d'individus ayant la modalité X_i **sachant** qu'ils ont la modalité Y_j .

$$f_{i|j} = \frac{n_{ij}}{n_{.j}}$$

Propriété (Indépendance)

X et Y sont indépendantes si les fréquences conditionnelles sont égales aux fréquences marginales :

$$f_{i|j} = f_{i.} \quad \text{pour tout } i, j$$

Relation entre deux Variables Quantitatives

Définition

Le **nuage de points** est la représentation graphique des couples d'observations (x_i, y_i) dans un plan.

- Il permet de visualiser la **forme** de la relation (linéaire, non linéaire, absence de relation) et son **sens** (positive ou négative).

La Covariance ($\text{cov}(X, Y)$)

Définition

La **covariance** mesure la tendance des deux variables à varier ensemble.

$$\text{cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Propriété (Formule de Calcul)

$$\text{cov}(X, Y) = \left(\frac{1}{n} \sum_{i=1}^n x_i y_i \right) - \bar{x} \bar{y}$$

- $\text{cov} > 0$: Relation positive (tendances similaires).
- $\text{cov} < 0$: Relation négative (tendances opposées).
- $\text{cov} \approx 0$: Absence de relation **linéaire**.

Le Coefficient de Corrélation Linéaire (r)

Définition

Le **coefficient de corrélation linéaire** normalise la covariance.

$$r = \frac{\text{cov}(X, Y)}{s_X s_Y}$$

- $r \in [-1, 1]$.
- $r = 1$: Corrélation linéaire positive parfaite.
- $r = -1$: Corrélation linéaire négative parfaite.
- $r = 0$: Absence de corrélation linéaire.

Corrélation $\neq$ Causalité

Une forte corrélation n'implique pas que X cause Y . Il peut y avoir une variable cachée (Z) ou une relation purement fortuite.

La Régression Linéaire Simple

Définition

La **régression linéaire simple** cherche la droite qui minimise la somme des carrés des erreurs (méthode des moindres carrés ordinaires - MCO).

$$\hat{Y} = aX + b$$

- Pente (a) :

$$a = \frac{\text{cov}(X, Y)}{s_X^2}$$

- Ordonnée à l'origine (b) :

$$b = \bar{y} - a\bar{x}$$

Propriété

La droite de régression passe toujours par le point moyen $(\bar{x}, \bar{y})$.

Exemple : Corrélation et Régression

Contexte : On étudie le lien entre les heures d'étude (X) et la note obtenue (Y) pour 6 étudiants.

i	x_i	y_i	x_i^2	y_i^2	$x_i y_i$
1	2	8	4	64	16
2	3	10	9	100	30
3	4	11	16	121	44
4	5	13	25	169	65
5	6	14	36	196	84
6	8	18	64	324	144
Σ	28	74	154	974	383

Exemple : Solutions (Bivariée)

Calculs préliminaires : $n = 6$, $\bar{x} = 28/6 = 4.67$, $\bar{y} = 74/6 = 12.33$.

$$s_X^2 = \frac{154}{6} - (4.67)^2 = 25.67 - 21.81 = 3.86, \quad s_X = 1.96$$

$$s_Y^2 = \frac{974}{6} - (12.33)^2 = 162.33 - 152.03 = 10.30, \quad s_Y = 3.21$$

$$\text{cov}(X, Y) = \frac{383}{6} - 4.67 \times 12.33 = 63.83 - 57.58 = 6.25$$

Corrélation : $r = \frac{6.25}{1.96 \times 3.21} = \frac{6.25}{6.29} = 0.99$ (très forte corrélation positive).

Régression :

$$a = \frac{6.25}{3.86} = 1.62, \quad b = 12.33 - 1.62 \times 4.67 = 4.76$$

$$\hat{Y} = 1.62X + 4.76$$

Prédiction : Si un étudiant étudie 7h : $\hat{y} = 1.62 \times 7 + 4.76 = 16.1$.

Exercices

- ❶ **Indépendance Conditionnelle** Un tableau de contingence croise "Sexe" (H/F) et "Réussite à l'examen" (Oui/Non).
 - Expliquer comment vérifier l'indépendance en utilisant les fréquences conditionnelles.
 - Donner un exemple numérique où les variables sont indépendantes.
- ❷ **Calcul de Corrélation** Soient les données : $\bar{x} = 10$, $\bar{y} = 5$, $s_X = 2$, $s_Y = 1$, $\text{cov}(X, Y) = 1.5$.
 - Calculer le coefficient de corrélation r .
 - Interpréter la force et le sens de la relation.
- ❸ **Régression et Prédiction** En utilisant les résultats de l'exercice 2 :
 - Déterminer l'équation de la droite de régression de Y en X .
 - Prédire la valeur de Y si $X = 12$.
 - Vérifier que la droite passe par $(\bar{x}, \bar{y})$.

- 4 **Publicité et Ventes** Une entreprise a collecté les données suivantes sur 8 mois :

Mois	1	2	3	4	5	6	7	8
Pub (kDH)	10	15	12	20	18	25	22	30
Ventes (kDH)	100	120	110	140	135	160	150	180

- Tracer le nuage de points.
 - Calculer $\text{cov}(X, Y)$, r et interpréter.
 - Déterminer la droite de régression et estimer les ventes pour un budget pub de 35 kDH.
- 5 **Tableau de Contingence** On croise "Filière" (GI/GE/TM) et "Mention" (Passable/AB/B/TB) sur 120 étudiants.
- Construire un tableau de contingence fictif cohérent.
 - Calculer les fréquences marginales et conditionnelles.
 - La mention semble-t-elle dépendre de la filière ?

- ⑥ **Corrélation $\neq$ Causalité** On observe une forte corrélation positive entre les ventes de glaces et les noyades.
- Est-ce que les glaces causent les noyades ? Expliquer.
 - Quelle pourrait être la variable cachée ?
- ⑦ **Corrélation Nulle** Donner un exemple de 6 couples (x_i, y_i) tels que $r \approx 0$ mais où il existe une relation non linéaire évidente.
- ⑧ **Comparaison de Groupes** Notes de statistique par groupe : Groupe A (12, 14, 15, 13, 16), Groupe B (8, 10, 11, 9, 12).
- Calculer $\bar{x}_A$, $\bar{x}_B$, s_A , s_B .
 - Quel groupe a les meilleures performances ? Le plus homogène ?
 - Tracer les deux boxplots côte à côte.
- ⑨ **Coefficient de Détermination** Si $r = 0.8$, calculer r^2 et interpréter : quelle proportion de la variance de Y est expliquée par X ?

Exercices Type Examen

Niveau 1 : Tableaux et Graphiques

Exercice Type Examen 1.1

Contexte : On mesure le temps de réponse (en ms) de 60 requêtes sur un serveur.

Classe (ms)	$[0, 50[$	$[50, 100[$	$[100, 150[$	$[150, 200[$	$[200, 300]$
Effectif n_i	8	18	20	10	4

- 1 Compléter le tableau : c_i , h_i , f_i , N_i , F_i , d_i .
- 2 Tracer l'histogramme (attention aux amplitudes inégales).
- 3 Tracer l'ogive et estimer graphiquement la médiane.

Exercice Type Examen 1.2

Contexte : Nombre de bugs corrigés par jour sur 30 jours : 0(5), 1(8), 2(10), 3(5), 4(2).

- 1 Construire le tableau complet (n_i, f_i, N_i, F_i) .
- 2 Tracer le diagramme en bâtons.
- 3 Identifier le mode.

1.3 : On interroge 100 utilisateurs sur leur système d'exploitation : Windows(45), Linux(30), macOS(20), Autre(5).

- 1 Construire le tableau des fréquences.
- 2 Représenter par un diagramme en barres et un diagramme circulaire.
- 3 Quel graphique est le plus adapté ? Justifier.

1.4 : Satisfaction de 80 clients : Très insatisfait(5), Insatisfait(15), Neutre(20), Satisfait(30), Très satisfait(10).

- 1 Construire le tableau avec effectifs cumulés.
- 2 Peut-on calculer la médiane ? Si oui, la déterminer.
- 3 Peut-on calculer la moyenne ? Justifier.

Niveau 2 : Position et Dispersion

Exercice Type Examen 2.1

Contexte : Durées d'exécution (en secondes) de 50 programmes.

Classe (s)	[0, 2[	[2, 4[	[4, 6[	[6, 10[	[10, 20]
Effectif n_i	10	15	12	8	5

- 1 Calculer $\bar{x}$, Me , Mo (par interpolation si nécessaire).
- 2 Calculer s^2 , s et CV .
- 3 Calculer Q_1 , Q_3 et IQR .
- 4 Commenter l'asymétrie de la distribution.

Exercice Type Examen 2.2

Contexte : Notes (sur 20) de 40 étudiants à un examen.

Classe	$[0, 8[$	$[8, 10[$	$[10, 12[$	$[12, 16[$	$[16, 20]$
n_i	4	8	14	10	4

- 1 Calculer $\bar{x}$, Me , Mo .
- 2 Calculer s et CV . La série est-elle homogène ?
- 3 Tracer un boxplot schématique.
- 4 Quel pourcentage d'étudiants a une note ≥ 10 ?

2.3 : Deux groupes ont passé le même test :

- Groupe A : $\bar{x}_A = 12$, $s_A = 3$, $n_A = 25$.
- Groupe B : $\bar{x}_B = 14$, $s_B = 2$, $n_B = 30$.

- ① Quel groupe a les meilleures performances en moyenne ?
- ② Quel groupe est le plus homogène ? (Calculer les CV.)
- ③ Calculer la moyenne globale des deux groupes réunis.

2.4 : Série brute : 5, 7, 8, 8, 9, 10, 10, 10, 12, 15, 50.

- ① Calculer $\bar{x}$, Me , Mo , E , s , IQR .
- ② La valeur 50 est-elle aberrante ? (Critère : $> Q_3 + 1.5 \times IQR$.)
- ③ Quel indicateur de position est le plus robuste ?

Niveau 3 : Forme et Concentration

Exercice Type Examen 3.1

Contexte : Salaires mensuels (en kDH) de 100 employés.

Classe	[4, 6[	[6, 8[	[8, 10[	[10, 15[	[15, 30]
n_i	20	35	25	15	5

- 1 Calculer $\bar{x}$, Me , Mo , s .
- 2 Calculer le coefficient d'asymétrie de Pearson A_P .
- 3 Interpréter l'asymétrie.
- 4 Construire la courbe de Lorenz et calculer l'indice de Gini.

Exercices Type Examen 3.2 à 3.4

3.2 : Une distribution a : $\bar{x} = 100$, $Me = 95$, $Mo = 90$, $s = 20$.

- 1 Calculer A_P et interpréter.
- 2 Dessiner schématiquement la forme de la distribution.

3.3 : Parts de marché de 5 entreprises : 5%, 10%, 15%, 30%, 40%.

- 1 Calculer P_i et Q_i cumulés.
- 2 Tracer la courbe de Lorenz.
- 3 Calculer l'indice de Gini et interpréter.

3.4 : Un analyste trouve $\gamma_2 = 2$ pour des temps de réponse.

- 1 La distribution est-elle leptokurtique ou platykurtique ?
- 2 Quelles implications pour la fiabilité du système ?

Niveau 4 : Bivariée (Complet)

Exercice Type Examen 4.1 (1/2)

Contexte : On étudie le lien entre le temps de développement (X , en heures) et le nombre de bugs (Y) pour 8 projets.

Projet	1	2	3	4	5	6	7	8
X (heures)	10	15	20	25	30	35	40	50
Y (bugs)	12	10	8	7	6	5	4	3

- 1 Tracer le nuage de points. Quelle tendance observez-vous ?
- 2 Calculer $\bar{x}$, $\bar{y}$, s_X , s_Y .
- 3 Calculer $\text{cov}(X, Y)$ et le coefficient de corrélation r .

Exercice Type Examen 4.1 (2/2)

- ④ Déterminer l'équation de la droite de régression de Y en X .
- ⑤ Prédire le nombre de bugs pour un projet de 45 heures.
- ⑥ Calculer r^2 et interpréter.
- ⑦ La relation observée implique-t-elle que plus de temps de développement *cause* moins de bugs ? Discuter.

4.2 : Tableau croisé : Réussite (Oui/Non) vs Filière (GI/GE/TM).

	GI	GE	TM
Oui	35	28	22
Non	15	12	8

Calculer les fréquences conditionnelles et conclure sur l'indépendance.

4.3 : Données : $\bar{x} = 20$, $\bar{y} = 50$, $s_X = 5$, $s_Y = 10$, $\text{cov}(X, Y) = 40$. Calculer r , la droite de régression, et prédire Y pour $X = 25$.

4.4 : On observe $r = -0.85$ entre la température et la consommation électrique.

- 1 Interpréter le signe et la force de la corrélation.
- 2 Donner un exemple de variable cachée possible.

Conclusion et Formulaire

- **Typologie** : La nature de la variable dicte les outils.
- **Position** : $\bar{x}$ (sensible), Me (robuste), Mo (fréquence).
- **Dispersion** : s (absolue), CV (relative), IQR (robuste).
- **Forme** : Asymétrie (γ_1) et Aplatissement (γ_2).
- **Relation** : Tableau croisé (qualitatif), r et Régression (quantitatif).

Formulaire Récapitulatif (Essentiel)

Position

- $\bar{x} = \sum f_i x_i$
- Me (Interpolation) : $L + h \cdot \frac{0.5 - F_{\text{avant}}}{f_{\text{classe}}}$
- G (Géométrique) : $(\prod x_i)^{1/n}$

Dispersion

- $s^2 = \sum f_i x_i^2 - \bar{x}^2$
- $s = \sqrt{s^2}$
- $CV = s/\bar{x}$
- $IQR = Q_3 - Q_1$

Forme et Concentration

- Asymétrie $\gamma_1 = \mu_3/s^3$
- Kurtosis $\gamma_2 = (\mu_4/s^4) - 3$
- Gini (Approché) :
 $1 - \sum (P_i - P_{i-1})(Q_i + Q_{i-1})$

Bivariée

- $\text{cov}(X, Y) = \sum f_{ij} x_i y_j - \bar{x} \bar{y}$
- $r = \frac{\text{cov}(X, Y)}{s_X s_Y}$
- Pente $a = \text{cov} / s_X^2$

- 1 Statistique Descriptive, Presses Universitaires de Rennes.
- 2 Statistique Descriptive, Pearson Education.
- 3 Introduction à la Statistique, De Boeck Supérieur.